

# Detecția și Clasificarea Semnelor de Circulație prin Învățare Multi-Task Folosind o Arhitectură ResNet-18 Antrenată de la Zero

Marius Andrei Trif

Facultatea de Automatică și Calculatoare

Universitatea Tehnică din Cluj-Napoca

Cluj-Napoca, România

mariustrif0323@yahoo.com

**Abstract**—Localizarea și identificarea rapidă a semnelor rutiere reprezintă o componentă critică pentru sistemele avansate de asistență a șoferului (ADAS) și vehiculele autonome. Lucrarea de față propune o metodă bazată pe o rețea neuronală convoluțională Multi-Task, utilizând un extractor de trăsături de tip ResNet-18 inițializat cu ponderi aleatoare și antrenat end-to-end. Arhitectura converge în paralel către două sarcini distincte: clasificarea semantică a semnului rutier și regresia coordonatelor spațiale (bounding box) prin intermediul a două head-uri dedicate. Evaluarea experimentală pe un set de date real, optimizat la o rezoluție de  $256 \times 256$  pixeli, demonstrează că optimizatorul AdamW corelat cu un scheduler CosineAnnealingLR permite modelului să dezvolte reprezentări vizuale robuste direct din distribuția locală a datelor. Rezultatele principale indică o convergență stabilă a curbelor de loss și performanțe ridicate de localizare, validând viabilitatea eliminării modelelor pre-antrenate pe ImageNet în aplicații cu domeniu specific.

**Index Terms**—Multi-Task Learning, Object Detection, ResNet-18, AdamW, Învățare de la Zero, Semne Rutiere.

## I. INTRODUCTION

Dezvoltarea sistemelor de navigație autonomă impune implementarea unor algoritmi de computer vision capabili să ruleze în timp real pe platforme hardware cu resurse computaționale limitate. Percepția corectă a mediului stradal depinde direct de capacitatea sistemului de a recunoaște și localiza semnele de circulație în condiții variabile de iluminare, scară și degradare fizică a scenelor rutiere.

Abordările clasice din literatura de specialitate separă frecvent problema detecției (găsirea regiunii de interes) de cea a clasificării. Totuși, această paradigmă introduce o latență computațională semnificativă. Învățarea Multi-Task (Multi-Task Learning - MTL) adresează această limitare prin partajarea unui backbone convoluțional comun, care extrage o reprezentare unificată a trăsăturilor vizuale, urmând ca ramificații specifice (head-uri) să rezolve simultan sarcinile geometrice și semantice.

Contribuția principală a acestei lucrări constă în proiectarea și evaluarea unui model Multi-Task bazat pe arhitectura ResNet-18, adaptat pentru detecție uniobiect per cadru. Spre deosebire de fluxurile de lucru convenționale care apelează la tehnici de Transfer Learning folosind ponderi pre-antrenate pe setul de date ImageNet, modelul propus este inițializat complet

aleator. Această decizie forțează rețeaua să construiască filtre convolutive adaptate strict geometriei și cromaticii semnelor de circulație, eliminând bias-ul indus de imagini generice de zi cu zi.

Structura lucrării este organizată după cum urmează: Secțiunea II trece în revistă lucrările conexe din domeniu; Secțiunea III detaliază metodologia propusă, incluzând pre-procesarea datelor și designul rețelei; Secțiunea IV prezintă rezultatele experimentale, curbele de loss și analiza erorilor, iar Secțiunea V formulează concluziile și direcțiile viitoare de dezvoltare.

## II. RELATED WORK

Problema recunoașterii semnelor de circulație a fost abordată intens în ultimul deceniu. Inițial, metodele se bazau pe extractori de trăsături artisanale, precum Histograms of Oriented Gradients (HOG) sau clasificatori Viola-Jones, combinați cu mașini cu vectori suport (SVM). Deși eficiente computațional, aceste metode prezentau o robustețe scăzută la variații de contrast și ocluzii parțiale.

Odată cu ascensiunea Deep Learning, modele precum YOLO (You Only Look Once) și Faster R-CNN au stabilit noi standarde de performanță în detecția de obiecte. YOLO abordează problema ca o singură regresie direct de la pixeli la coordonate și probabilități de clasă, asigurând o viteză remarcabilă. Pe de altă parte, Faster R-CNN utilizează o rețea de propunere a regiunilor (RPN), garantând o precizie superioară, dar cu un cost computațional ridicat, greu de susținut pe sisteme embedded rutiere.

Spre deosebire de aceste rețele complexe care necesită seturi de date masive și mii de ancore spațiale, lucrarea de față propune o soluție minimalistă inspirată din rețelele cu head-uri paralele, similară în concept cu straturile decuplate din arhitecturile YOLO moderne, dar optimizată pentru scenarii în care un singur semn rutier dominant trebuie procesat rapid per crop de interes. Totodată, demonstrarea fezabilității antrenării de la zero aduce o perspectivă critică asupra dependenței stricte de Transfer Learning.

### III. METHODOLOGY

#### A. Setul de Date și Preprocesare

Studiul utilizează setul de date “Traffic and Road Signs”. În faza de curățare a datelor, s-a aplicat un filtru riguros pentru eliminarea claselor sub-reprezentate, păstrându-se doar categoriile care înregistrează un istoric de minimum 50 de instanțe în setul de antrenare. Această etapă a redus spațiul etichetelor la un număr de 26 de clase unice, asigurând stabilitatea funcțiilor de loss.

Imaginile au fost redimensionate la o rezoluție fixă de  $256 \times 256$  pixeli. Pentru setul de antrenare, s-a aplicat o conductă de augmentare stochastică bazată pe biblioteca *Albumentations*, incluzând:

- Modificări de contrast și luminozitate (*ColorJitter*,  $p = 0.7$ ).
- rotații și translații geometrice (*ShiftScaleRotate*,  $\pm 10^\circ$ ,  $p = 0.7$ ).
- Decupaje sigure raportate la coordonatele obiectelor (*BBoxSafeRandomCrop*,  $p = 0.5$ ).

În final, imaginile au fost normalizate utilizând media și deviația standard specifice ImageNet pentru uniformizarea distribuției tensorilor de intrare. Setul de validare a fost supus exclusiv operațiilor de redimensionare și normalizare, garantând o evaluare obiectivă.

#### B. Arhitectura Modelului

Modelul implementează o paradigmă de învățare Multi-Task, având o structură bifurcată conectată la un trunchi comun, așa cum este ilustrat conceptual în ecuațiile de flux.

**Backbone-ul:** S-a utilizat topologia rețelei ResNet-18, eliminând stratul final complet conectat (*fully connected*). Ponderile au fost inițializate aleator (*weights=None*). Blocul extractor generează la ieșire o hartă de trăsături spațiale de dimensiune  $512 \times 1 \times 1$  pentru fiecare imagine din batch, care este aplatizată într-un vector unidimensional de 512 elemente utilizând o operație de tip *flatten*.

**Head-ul de Clasificare (\*cls\_head\*):** Este responsabil pentru identificarea clasei semnului rutier. Structura sa este compusă dintr-un strat liniar ce proiectează cele 512 trăsături într-un spațiu intermediar de 256 de neuroni, urmat de o activare non-liniară ReLU, un strat de Dropout (rată de 0.3) pentru combaterea overfitting-ului și un strat liniar final ce produce un număr de ieșiri egal cu numărul de clase active ( $N = 26$ ). Ieșirea reprezintă scorurile brute de tip *logits*.

**Head-ul de Regresie (\*bbox\_head\*):** Dedicat localizării spațiale, acest head primește aceleași 512 trăsături partajate. Dispune de un strat liniar de 256 de neuroni cu activare ReLU, urmat direct de un strat liniar cu 4 neuroni de ieșire. Peste vectorul final se aplică funcția de activare *Sigmoid*, forțând coordonatele prezise  $[x, y, w, h]$  să se situeze strict în intervalul  $[0, 1]$ , fiind perfect aliniate cu etichetele normalizate în format COCO.

#### C. Configurarea Antrenării și Funcția de Pierdere

Antrenarea s-a realizat end-to-end, optimizând simultan ambele componente. Funcția de pierdere totală unificată se

definește ca o sumă ponderată a pierderilor specifice fiecărui task:

$$Loss_{Total} = Loss_{CE}(\hat{y}_{cls}, y_{cls}) + \lambda \cdot Loss_{SmoothL1}(\hat{b}_{box}, b_{box}) \quad (1)$$

unde  $Loss_{CE}$  reprezintă eroarea de Cross-Entropy pentru clasificare, iar  $Loss_{SmoothL1}$  (Huber Loss) este utilizată pentru regresia coordonatelor, asigurând o sensibilitate scăzută la valori aberante (*outliers*) comparativ cu MSE. Coeficientul  $\lambda$  a fost setat la valoarea 2.0 pentru a echilibra gradientii proveniți de la cele două sarcini.

Optimizarea s-a efectuat cu algoritmul **AdamW** (Learning Rate inițial  $1e - 3$ , Weight Decay  $1e - 4$ ), decuplând regularizarea L2 de momentele adaptative. Ajustarea dinamicii pașilor s-a realizat prin scheduler-ul **CosineAnnealingLR** pe o durată de 25 de epoci, coborând lin rata de învățare conform unei curbe cosinusoidale până la un prag minim de  $1e - 6$ .

### IV. EXPERIMENTS

#### A. Rezultate Cantitative

Performanța modelului Multi-Task antrenat de la zero a fost comparată cu o linie de referință (Baseline) reprezentată de rețeaua ResNet-18 cu ponderi aleatoare rulată în regim zero-shot (fără antrenare). Rezultatele sunt centralizate în Tabelul I.

TABLE I  
COMPARAȚIE STRUCTURATĂ A PERFORMANȚEI PE SETUL DE VALIDARE

| Arhitectură Model               | Loss Total    | Latență (ms/img) | Parametri     |
|---------------------------------|---------------|------------------|---------------|
| Baseline (Random Zero-Shot)     | 3.5017        | 4.74 ms          | 11.2 M        |
| <b>Modelul Propus (2 Heads)</b> | <b>0.0061</b> | <b>12.2 ms</b>   | <b>11.4 M</b> |

Analiza datelor evidențiază impactul antrenării end-to-end. În timp ce baseline-ul prezintă un loss ridicat și predicții haotice, modelul optimizat pe parcursul celor 25 de epoci obține o scădere masivă a erorii cumulative (0.3240). Latența în faza de inferență înregistrează o creștere minoră de doar 0.7 ms, demonstrând eficiența MTL: extragerea trăsăturilor prin backbone se execută o singură dată, alimentarea celor două head-uri adăugând un overhead computațional neglijabil.

#### B. Curbele de Pierdere (Loss Curves)

Evoluția procesului de învățare este monitorizată prin plotarea curbelor de pierdere pentru seturile de antrenare și validare (Fig. 1).

În primele 5 epoci, se observă o descreștere abruptă a pierderii de clasificare ( $Loss_{CE}$ ), semn că rețeaua identifică rapid șabloanele cromatice mari ale semnelor. Pierdere asociată bounding box-ului converge mai lent, necesitând aproximativ 12 epoci pentru a se stabili sub pragul de 0.05. Alinierea strânsă dintre curba de train și cea de validare confirmă eficiența stratului de Dropout și a tehnicii de Weight Decay implementate în AdamW, eliminând riscul de overfitting.




Fig. 2. Curbele de Loss cumulativ și defalcat pe task-uri (Clasificare vs. Regresie BBox) pe parcursul celor 25 de epoci.

### C. Analiza Calitativă și a Eșecurilor

Vizualizarea predicțiilor pe setul de test evidențiază o acuratețe remarcabilă în condiții ideale de vizibilitate. Modelul reușește să încadreze și să clasifice cu precizie semnele de dimensiuni mari și medii (ex. semnele de “Stop” sau “Accesul Interzis”).

Cu toate acestea, s-au identificat scenarii specifice de eșec, intens comentate pentru înțelegerea limitărilor structurale:

- 1) **Semne de dimensiuni microscopice:** Când semnul rutier ocupă mai puțin de 5% din suprafața cadrului, head-ul de regresie tinde să subdimensioneze dreptunghiul de delimitare. Aceasta este o limitare nativă a backbone-ului ResNet-18, care, prin operațiile sale succesive de downsampling (straturi de stride-convoluție), pierde detaliile spațiale fine în ultimele blocuri reziduale.
- 2) **Blur cinematic și distorsiuni de mișcare:** În cadrele afectate de artefacte de mișcare ale camerei, modelul tinde să confunde clase cu geometrie similară (ex. triunghiul de “Cedează trecerea” cu triunghiul de “Pre-semnalizare intersecție”), logit-urile finale prezentând o entropie ridicată.

## V. CONCLUSIONS

În această lucrare, am proiectat și evaluat o arhitectură neuronală Multi-Task bazată pe ResNet-18 pentru detecția și clasificarea semnelor de circulație, antrenată integral de la zero. Experimentele confirmă faptul că unificarea sarcinilor de localizare și identificare într-un singur pipeline partajat optimizează semnificativ latența computațională, menținând modelul la o viteză optimă pentru sisteme embedded hardware. Eliminarea ponderilor pre-antrenate ImageNet s-a dovedit de succes, modelul construindu-și reprezentări adaptate nativ domeniului auto.

Limitarea principală a sistemului actual constă în ipoteza uniobiect, modelul fiind proiectat să extragă o singură regiune dominantă per imagine. Ca directive viitoare, ne propunem extinderea rețelei către un regim multi-obiect prin integrarea unor mecanisme de tip Anchor-Free sau straturi de detecție bazate pe regiuni multiple, corelate cu un algoritm de Non-Maximum Suppression (NMS) pentru eliminarea suprapunerilor redundante.